
Projet de finance quantitative

Auteurs : Yanis AHDJOUDJ, Nassim SASSI, El Mehdi AGUNAOU,
Lucas DIAZ

Résumé

Les données ESG requièrent de plus en plus d'attention, elles sont au coeur des débats et profitent de plus en plus aux investisseurs. L'objet de notre travail est de reproduire l'article SEEKING SIGNALS FROM ESG DATA de Bloomberg s'articulant autour d'application de modèle de machine learning sur des données ESG et de l'interprétation des modèles boîtes noires. L'objectif est de comparer un portefeuille d'action d'entreprises comportant des données ESG à différents indices de référence.

L'ensemble de notre travail est accessible via le repository GitHub suivant : <https://github.com/YanisAhdjoudj/Projet-Finance-Quant>

Table des matières

1	Introduction	1
2	Données ESG	2
2.1	ESG Data Overview	2
2.2	Extraction de données ESG à partir de Yahoo Finance avec R	3
2.2.1	Récupération des données ESG	3
2.2.2	Évaluation des scores ESG	3
3	Imputation des données	5
3.1	Motivations et objectifs	5
3.2	Méthodes utilisées	5
4	Modélisation	6
4.1	Problématique	6
4.2	Résultats	6
5	Interprétation des résultats	8
5.1	Présentation de la méthode shapley additive explanations	8
5.2	Interprétation des variables	8
6	Construction de portefeuilles	11
6.1	Méthodologie	11
6.2	Construction d'un portefeuille naïf	11
7	Résultats et backtesting	12
7.1	Rendements des portefeuilles	12
7.2	Comparaison avec les benchmarks	12
7.3	Backtesting par Fama-French	13
8	Conclusion	14

Chapitre 1

Introduction

La prise de conscience des enjeux ESG (Environnementaux, Sociaux et de Gouvernance) s'est rapidement propagée, les investisseurs intégrant de plus en plus d'informations extra-financières dans leur analyse de portefeuille. Les sociétés répondent à cette demande en fournissant de plus en plus de données. En 2011, moins de 20% des sociétés cotées au S&P 500 divulguaient leurs données ESG. Cependant, on remarque une implication croissante concernant les données ESG, à l'horizon 2016, le nombre de sociétés émettant des rapports de durabilité ou intégrés a augmenté pour atteindre plus de 80%.

Cette sensibilisation accrue aux questions ESG est due à trois facteurs. Premièrement, les consommateurs privilégient de plus en plus les choix qu'ils considèrent comme plus durables, plus sains et plus intelligents. Il s'agit d'une évolution générale des préférences des consommateurs, qui se traduit dans leurs décisions d'investissement par une préférence pour les entreprises ayant un profil ESG positif. Deuxièmement, les chercheurs en finance ont trouvé des preuves que la force d'une entreprise dans les critères ESG est associée à des impacts financiers positifs à long terme, ce qui fait de ces entreprises des investissements intéressants. Troisièmement, la disponibilité de données ESG plus complètes permet d'effectuer davantage de recherches à partir de celles-ci, créant ainsi des options d'investissement plus robustes et fondées sur des données, basées sur les facteurs ESG. (Bloomberg - "Seeking Signals from ESG Data")

De nombreux investisseurs peinent à intégrer ces facteurs ESG susceptibles d'améliorer la performance ajustée du risque d'un portefeuille. De nombreux travaux académiques étudiant la relation entre la responsabilité sociale des entreprises et la performance d'une action présentent des conclusions contradictoires en la matière. Nous examinerons ci-dessous les principaux pièges dans lesquels tombent habituellement, les investisseurs ainsi que les raisons sous-jacentes.

Le présent document se concentre sur la relation entre les données ESG et l'impact financier. Plus précisément, il aborde l'utilisation de techniques avancées de Machine Learning appliquées aux données ESG pour créer un portefeuille d'actions offrant un rendement supérieur et une volatilité inférieure à son indice de référence. Il existe des preuves qu'une telle approche peut fonctionner. Une étude (Barnett et Salomon, 2006) a montré qu'il existe une relation curviligne entre la responsabilité sociale et la performance financière. Une étude plus récente (Eccles et al., 2014) a montré que les entreprises à forte durabilité avaient de meilleures performances d'investissement que leurs homologues à faible durabilité. Nous allons démontrer dans cette études qu'en appliquant des techniques avancées de Machine Learning aux données ESG, nous sommes en mesure de créer un portefeuille présentant des caractéristiques de risque et de rendement supérieures.

Chapitre 2

Données ESG

2.1 ESG Data Overview

Les données que nous avons à notre disposition sont issues d'une extraction Bloomberg. Elles comptent différents indicateurs ESG pour 46 entreprises européennes sur une période de 15 ans. La période couverte par ces données va de 2005 à 2019.

L'une des difficultés des données ESG est qu'il y a beaucoup de valeurs manquantes. Cela est dû à deux raisons. Premièrement, la plupart des mesures ESG sont déclarées par les entreprises elles-mêmes et celles-ci ne sont pas tenues de les déclarer. Deuxièmement, certaines mesures ESG spécifiques peuvent s'appliquer fortement à certaines industries et pas du tout à d'autres.

Variables	Valeurs manquantes
Entreprises	0.00%
Dates	0.00%
NUMBER EMPLOVEES CSR	9.42%
AUDIT COMMITTEE MEETINGS	14.35%
SAY PAY SUPPORT LEVEL	80.14%
TOT OTHER COMP AW TO CEO & EQUIV	52.90%
TOTAL EXEC PAY AS PCT OPEX	21.16%
TOT SALARIES PAID TO CEO & EQUIV	20.15%
TOT SALARIES & BNS PD TO EXECS	18.99%
TOT N EQTY INCENT GIVEN TO EXECS	94.35%
SAY PAY NUMBER OF VOTES FOR	80.15%
TOT EXEC PAY AS PCT SG&A NET R&D	42.03%
TOT OPTION AWARDS GIVEN TO EXECS	86.23%
TOT EXEC PAY AS PCT TOT PSNL EXP	27.10%
TOT N EQT INCENT GVN TO CEO & EQ	94.35%
PCT BOD COMP PD IN STK AWD	73.62%
NUM EXECUTIVE CHANGES	20.00%
AVERAGE BOD TOTAL COMPENSATION	22.75%
ESG DISCLOSURE SCORE	10.43%
CFO TENURE AS OF FY END	52.03%
CHG OF CTRL BFIT GOLD CHUTE AGR	36.52%
CLAWBACK PROVISION FOR EXEC COMP	36.81%
GENDER PAY GAP BREAKOUT	58.26%
BLANK CHECK PREFERRED AUTHORIZED	91.45%

Ce défaut de valeurs constitue l'un des principaux problèmes des travaux réalisés sur les données ESG.

On constate également que ces données ESG sont exclusivement des données de Gouvernance. Notre analyse portera donc sur une étude spécifique de ces données ESG.

2.2 Extraction de données ESG à partir de Yahoo Finance avec R

2.2.1 Récupération des données ESG


L'extraction de données ESG peut s'avérer compliquée, c'est pourquoi nous avons extrait les informations ESG à partir de Yahoo Finance dans le but de compléter notre analyse. Yahoo Finance fournit des scores ESG totaux, des scores de risque environnemental, social et de gouvernance, ainsi que des niveaux de controverse. Tous ces scores sont compilés par Sustainalytics qui appartient désormais à Morningstar. Le détail et l'explication du procédé est disponible en annexe. Nous avons récupéré des informations pour les 500 entreprises du S&P500, à savoir l'entreprise, son secteur d'activité, l'industrie qui la caractérise (Wikipedia) ainsi que les scores ESG (Yahoo Finance).

Lors du Web Scrapping, nous devons incorporer des temps d'attente (aléatoires) avant d'essayer de récupérer des informations de Yahoo Finance pour que notre scraping ait le comportement d'un humain qui clique. En cas de dépassement du délai d'attente sans récupération de la donnée, nous demandons à la boucle de réessayer, mais d'attendre un peu plus longtemps. Après 10 tentatives, la boucle abandonne et on suppose qu'il n'y a pas d'informations sur les critères ESG pour l'entreprise en question, ce qui est en fait le cas la plupart du temps.

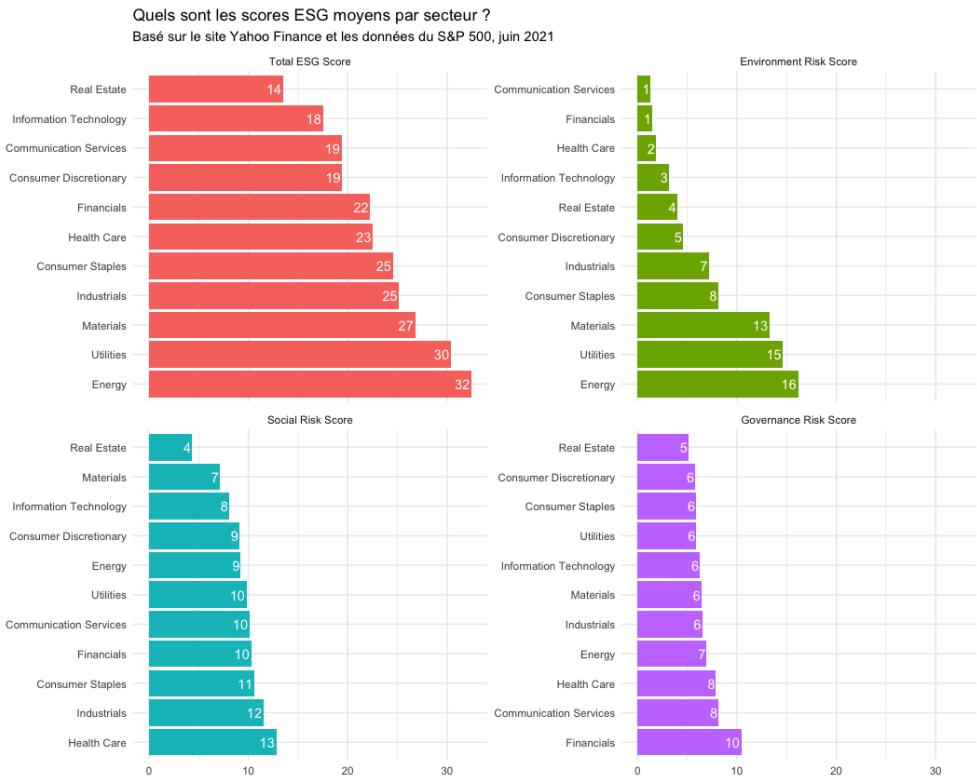
2.2.2 Évaluation des scores ESG

Nous avons vérifié ce que notre scraping nous a permis de récupérer. Tout d'abord, vérifions la couverture globale de notre échantillon : 90%

La figure 1 nous donne la couverture par secteur. Toutes les sociétés immobilières ont des scores ESG, alors que seulement un peu plus des trois quarts des services de communication présentent cette information.

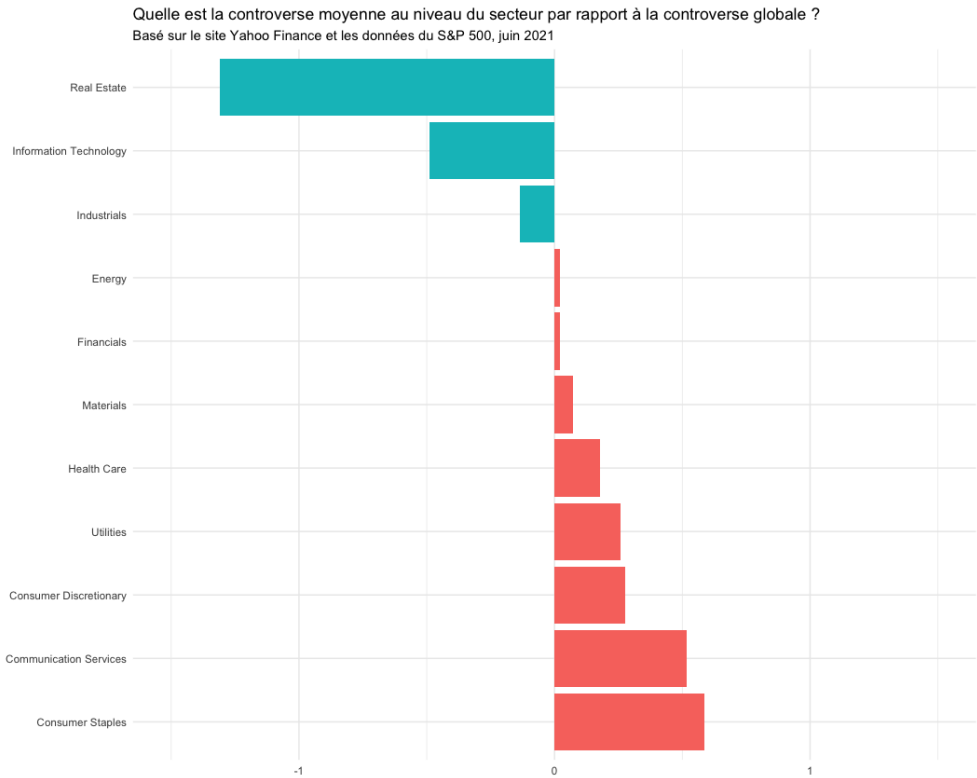


Ensuite, dans la figure 2 nous avons regardé les scores ESG moyens par secteur. Par exemple, le secteur de l'immobilier a le score ESG total le plus bas, ce qui indique le degré le plus faible de risque pour la valeur commerciale d'un secteur en raison des risques environnementaux, sociaux et de gouvernance. Le secteur financier présente le risque environnemental le plus faible, tandis que le secteur de l'énergie (du moins la partie incluse dans le SP 500) est le plus exposé aux risques environnementaux.



Enfin, nous avons décidé de nous intéresser au niveau moyen de controverse, qui mesure dans quelles mesures les entreprises sont impliquées dans des incidents et des événements susceptibles d’avoir un impact négatif sur les parties prenantes, l’environnement ou leurs activités.

Nous avons représenté graphiquement la controverse de chaque secteur par rapport à la controverse moyenne globale dans la figure 3. L’immobilier et les technologies de l’information semblent être beaucoup moins controversés que les biens de consommation de base et les services de communication.



Chapitre 3

Imputation des données

3.1 Motivations et objectifs

Comme nous avons pu le voir, les données ESG, de par leur nature déclaratives et non réglementaires présentent presque systématiquement un taux de valeurs manquantes élevé. C'est une caractéristique qui, nous l'espérons, disparaîtra au fur et à mesure que les enjeux ESG prendront de l'importance dans les décisions d'investissement et dans la réglementation. Du fait de la popularité de ces sujets nous espérons voir dans les années à venir les entreprises fournir plus aisément ces données, ce qui pourra permettre aux chercheurs de catégoriser plus rigoureusement le lien entre les facteurs ESG et le rendement.

Pour l'heure ce problème de valeur manquante doit être solutionné. En effet pour pouvoir exécuter certains des algorithmes mis en oeuvre dans ce travail il nous faut des données complètes. Du fait de la trop grande part de valeurs manquantes pour toutes les variables et du faible nombre d'observation dont nous disposons, il n'est pas possible d'appliquer un traitement classique des valeurs manquantes en les retirant simplement de la base. Il nous faut passer par des méthodes d'imputation de données. Nous testerons dans ce travail quatre méthodes différentes.

Une fois les données imputées nous pourrions exécuter nos différents modèles. Alors, au vu de leurs résultats sur les différentes bases nous pourrions déterminer quelle méthode est la plus optimale pour notre jeu de données.

3.2 Méthodes utilisées

Dans l'article original de Bloomberg seulement deux méthodes étaient utilisées, l'imputation par la moyenne et l'imputation par la méthode VAE. Nous proposons dans notre travail deux autres méthodes supplémentaires qui sont les méthodes d'imputation MICE (Multivariate Imputation by Chained Equations) et l'imputation par KNN.

La première imputation que nous effectuons est une imputation par la moyenne, elle nous servira de référence pour estimer la qualité de l'imputation par la suite.

Nous effectuons ensuite l'imputation par la méthode VAE (Variational Auto encoders), présente dans l'article de Bloomberg. Cette méthode permet de générer des données en utilisant de l'inférence statistique, celle-ci se base sur les auto-encodeurs utilisés dans les réseaux de neurones pour apprendre comment encoder et décoder un schéma.

Pour essayer de challenger ces deux méthodes nous avons ensuite utilisé la méthode MICE. Cette technique vise à imputer les valeurs manquantes en analysant les données des autres colonnes et en estimant la meilleure prédiction pour chaque valeur.

Enfin, toujours dans le but de challenger les méthodes utilisées dans l'article, nous avons également utilisé l'imputation par KNN. Cette méthode des k plus proches voisins consiste à attribuer une valeur à partir des observations se rapprochant le plus de l'observation comportant la valeur manquante.

Chapitre 4

Modélisation

4.1 Problématique

L'investissement basé sur les critères ESG est généralement considéré comme un investissement à long terme. Nous avons donc choisi d'utiliser ces données en les liant aux rendements à long terme. Pour cela, nous avons utilisé des méthodes de Machine Learning basées sur ces données dans un objectif de classification sur le rendement excédentaire annuel pour chaque action. Les rendements excédentaires annuels ont été mesurés par rapport à plusieurs indices de référence et ont été classés en deux catégories, les catégories ont été choisies de manière à ce que les classes soient relativement équilibrées. Nous avons pris une position long sur les rendements excédentaires de plus de +15%, la classe 2 ayant le reste des observations.

4.2 Résultats

Comme dans l'article, nous avons tout d'abord lancé un modèle sans imputation de valeurs manquantes en utilisant Xgboost. Les résultats sont les suivants :

En utilisant un Grid Search nous avons retenu les hyper-paramètres suivants pour le XGBoost : ('eta'= 0.3, 'max_depth'= 5, 'objective'= 'multi:softprob', 'num_class'= 2 , steps = 40)

	Precision	Recall	F1-Score	Support
0	0.57	0.70	0.63	79
1	0.43	0.31	0.36	59
Accuracy			0.53	138
Macro avg	0.50	0.50	0.49	138
Weighted avg	0.51	0.53	0.51	138

Après imputation par VAE nous avons tenté deux modèles, un modèle linéaire : la régression logistique dont les résultats sont les suivants :

	Precision	Recall	F1-Score	Support
0	0.57	0.56	0.56	77
1	0.45	0.46	0.46	61
Accuracy			0.51	138
Macro avg	0.51	0.51	0.51	138
Weighted avg	0.52	0.51	0.51	138

et un modèle non-linéaire : Random Forest qui a donné les résultats suivants :

	Precision	Recall	F1-Score	Support
0	0.57	0.83	0.68	77
1	0.50	0.21	0.30	61
Accuracy			0.56	138
Macro avg	0.54	0.52	0.49	138
Weighted avg	0.54	0.56	0.51	138

Les résultats des modèles, que ce soit avec ou sans imputation sont comme on pouvait s'y attendre décevant. Cela est dû au manque de fréquence et de la granularité dans les données. Presque toutes les variables concernent des données de gouvernance, nous ne disposons pas de données environnementales ou sociales.

Les autres méthodes d'imputations utilisées n'ont malheureusement pas été concluantes, entraînant des performances moindres que l'imputation par VAE sur les scores finaux à modèles égaux.

Le modèle de référence retenu pour le reste de notre travail sera donc le modèle de random forest avec les hyper-paramètres suivants (obtenus par grid search) :

```
(n_estimators=1000, criterion='gini', max_depth=9, min_samples_split=3, min_samples_leaf=2, min_weight_fraction_leaf=0.0, max_features='auto', max_leaf_nodes=None, min_impurity_decrease=0.0, min_impurity_split=None, bootstrap=True, oob_score=False, n_jobs=-1, random_state=1, verbose=0, warm_start=False, class_weight='balanced', ccp_alpha=0.0, max_samples=None)
```

Chapitre 5

Interprétation des résultats

5.1 Présentation de la méthode shapley additive explanations


5.2 Interprétation des variables

Dans cette section nous interpréterons les résultats par la méthode des valeurs de Shapley.

Cette méthode a été développée en théorie de jeux par en Lundberg et Lee en 2016. Elle va nous permettre d'étudier les variables les plus importantes dans le modèle mais également leur sens sur la variable cible (positif ou négatif).

Cette méthode consiste à moyenner l'impact d'une variable sur notre cible pour toutes les combinaisons de variables possibles.

En plus du caractère d'interprétabilité, l'objectif est de sélectionner les variables les plus importantes pour condenser les informations en éliminant les variables moins utiles et augmenter les performances du modèle. On relancera donc le modèle qui contiendra seulement les variables resélectionnées.




Le choix des variables retenues s'effectue en analysant l'importance des variables dans le modèle (graphique ci dessus) et en analysant la cohérence des interreprétations qui vont suivre.

D'après le graphe de `features_importance`, on décide de ne pas retenir les trois dernières variables du graphe, c'est à dire `CLAWBACK PROVISION FOR EXEC COMP`, `GENDER PAY GAP BREAKOUT` et `BLANK CHECK PREFERRED AUTHORIZED`.

Le graphique ci-après nous renseigne, en plus de l'ampleur, sur le sens d'agissement des variables sur notre cible. Il nous permet d'observer selon les valeurs hautes ou faibles de nos explicatives augmentent ou diminuent la probabilité de se trouver dans la tranche de rendement supérieur à 15% annuel.

Chaque point indique une valeur SHAP et mesure l'impact sur la valeur prédite (positif ou négatif). La couleur de ce point indique si la variable prend une valeur faible ou élevée (par rapport à elle-même). Plus on s'éloigne du 0 vers la droite, plus on aura une probabilité élevée de se trouver dans la tranche de rendement la plus haute, et inversement pour l'autre tranche.

Analysons donc le graphique d'interprétation des valeurs de Shap pour la classe 1 (rendement annuel supérieur à 15%).



L'interprétation par cette méthode permet en effet d'exploiter le sens des variables sur notre cible cependant il est fréquent que pour certaines variables, l'analyse de nous permet pas de conclure sur leur impact.

En effet les interprétations sont parfois nuancées comme pour les variables `TOT EXEC PAY AS PCT TOT PSNL EXP` et `TOT OPTION AWARDS GIVEN TO EXECS` pour lesquelles on peut dire que des valeurs importantes conduisent vers une plus grande probabilité de se trouver en classe 1. Cependant les amas de points violets perturbent la bonne lecture de l'analyse et ne permettent pas de trancher sur une conclusion nette.

De part cette même lecture, on élimine les résultats sur les interprétations des variables `ESG disclosure`, `Entreprises`, `TOT N EQT INCENT GVN TO CEO` et `PCT BOD COMP PD IN STK AWD`.

LA variable `TOTAL EXEC PAY AS PCT OPEX` est la variable la plus importante en terme de performance

du modèle. Cependant elle aussi ne présente pas d'interprétation nette, on aura tendance à dire que les hautes valeurs donne une meilleure probabilité de se trouver en classe 1.

Pour les variables suivantes, d'importantes valeurs vont engendrer un impact positif sur le rendement annuel. Il s'agit des variables SAY PAY NUMBER OF VOTES FOR, SAY PAY SUPPORT LEVEL, CFO TENURE AS OF FY END, AVERAGE BOD TOTAL COMPENSATION et TOT OTHER COMP AW TO CEO & EQUIV.

D'autres variables vont provoquer une meilleure probabilité d'appartenir à la classe de rendement supérieur à 15%, pour des valeurs plus faibles. Il s'agit de TOT SALARIES & BNS PD TO EXECS, TOT SALARIES PAID TO CEO EQUIV, TOT EXEC PAY AS PCT SG&A NET R&D et NUM EXECUTIVE CHANGES

Suite à ces résultats on sélectionne les principales variables qui ont des impacts clairs et cohérents sur la prévision du rendement.

Variables	Classe 1
Entreprises	o
SAY PAY SUPPORT LEVEL	x
TOT OTHER COMP AW TO CEO EQUIV	x
TOTAL EXEC PAY AS PCT OPEX	x
TOT SALARIES PAID TO CEO EQUIV	x
TOT SALARIES BNS PD TO EXECS	x
TOT N EQTY INCENT GIVEN TO EXECS	o
SAY PAY NUMBER OF VOTES FOR	x
TOT EXEC PAY AS PCT SG A NET RD	x
TOT OPTION AWARDS GIVEN TO EXECS	x
TOT EXEC PAY AS PCT TOT PSNL EXP	x
TOT N EQT INCENT GVN TO CEO EQ	o
PCT BOD COMP PD IN STK AWD	o
NUM EXECUTIVE CHANGES	x
AVERAGE BOD TOTAL COMPENSATION	x
ESG DISCLOSURE SCORE	o
CFO TENURE AS OF FY END	x
CHG OF CTRL BFIT GOLD CHUTE AGR	o
CLAWBACK PROVISION FOR EXEC COMP	o
GENDER PAY GAP BREAKOUT	o

TABLE (5.1) Variables retenues

Chapitre 6

Construction de portefeuilles

6.1 Méthodologie

A partir des résultats du modèle retenu nous décidons de créer deux types de portefeuilles, un portefeuille long only et un long short.

Pour la construction du premier portefeuille (long only) nous récupérons en sortie de modèle les actions qui ont été classé comme pouvant avoir un rendement annuel supérieur à 15%. Notre portefeuille sera alors constitué par ces actions qui seront toutes équipondérées en position long.

Pour le second portefeuille le principe est le même, les actions classées en + 15% annuel viendront constitué de façon équipondéré la partie long du portefeuille. Tandis que les actions qui sont classées en - 15% constitueront la partie short du portefeuille.

Dans l'article de Bloomberg, la technique utilisée était d'appliquer un modèle de classification multinomial qui donnera les choix de long / short / abstention. Cependant, avec nos données ce genre de modèle est irréalisable à cause de la rareté des revenus très négatifs qui constitueraient le portefeuille à shorter. Nous avons donc procédé autrement.

Premièrement, on classe les rendements supérieurs à 15% en classe 1 contre le reste en classe 0 et on prédit la partie long du portefeuille avec ce modèle. Deuxièmement, on classe les rendements inférieurs à -15% en classe 1 contre le reste en classe 0 et on prédit la partie short du portefeuille.

Les actions prédites par les 2 modèles poseront problème : nous avons eu donc recours aux probabilités prédites et nous avons sélectionné la plus extrême (plus probable).

De cette façon nous avons pu construire un portefeuille long/short avec deux modèles.

6.2 Construction d'un portefeuille naïf

Pour venir challenger nos résultats nous avons décidé de créer un portefeuille ESG naïf. Se reposant sur un score ESG global calculer par le site "sustainalytics" , nous nous mettons à la place d'un investisseur désirant investir sur des critères ESG. Cependant comme vu précédemment , les données ESG ne sont pas facile à acquérir et notre investisseur dispose seulement d'un score global qui lui sert de référence pour investir.

A partir de la nous avons construit un portefeuille naïf, basé uniquement sur le revenu et une contrainte d'investir au maximum 10% sur une entreprise. Cela reviendra donc à construire un portefeuille en mettant 10% sur les 10 entreprises ayant le meilleur score ESG global lors de l'année de la construction du portefeuille.

Chapitre 7

Résultats et backtesting

Pour chaque combinaison de modèle utilisé et Benchmark choisi, nous avons calculé les rendements moyens, volatilité et de Ratio de Sharpe.

7.1 Rendements des portefeuilles

Résultats des portefeuilles : Portfolio S&P500

Pour la Random Forest imputées par la méthode de VAE :

Métrique	Valeur
Return	37.4177
Volatility	20.7162
Sharpe Ratio	1.8062

Pour la Régression logistique imputées par la méthode de VAE

Métrique	Valeur
Return	30.4210
Volatility	18.6690
Sharpe Ratio	1.6295

Le modèle de Random Forest nous permet d'obtenir un portefeuille avec un meilleur rendement que celui de la régression logistique. Cependant la volatilité est plus élevée dans la Random Forest. Au global le ratio de Sharp est meilleur pour le portefeuille de la Random Forest.

Pour le portefeuille naïf :

Métrique	Valeur
Return	50,7888
Volatility	23,0636
Sharpe Ratio	2,2021

A notre grande surprise le portefeuille qui obtient le meilleur ratio de Sharp est notre portefeuille naïf basé uniquement sur un seul facteur ESG.

7.2 Comparaison avec les benchmarks

En choisissant le Benchmark : Euro stocks 50

Métrique	Valeur
Return	26.9337
Volatility	16.6873
Sharpe Ratio	1.6140

En choisissant le Benchmark : Euro Next 100

Métrique	Valeur
Return	28.1056
Volatility	17.2007
Sharpe Ratio	1.634

En choisissant le Benchmark : S&P500

Métrique	Valeur
Return	30.0238
Volatility	15.4497
Sharpe Ratio	1.943

Nos résultats nous sont satisfaisants. Les deux modèles ont battu l'Euro stocks 50 sur le ratio de Sharp. L'euro stock reste tout de même moins risqué. La forêt aléatoire est arrivée à dépasser le sharp ratio du Euro next 100 grâce au Return bien supérieur. Le benchmark du S&P 500 n'a pas été battu. On le surpasse en terme de rendement mais on rivalise pas niveau risque.

7.3 Backtesting par Fama-French

Dans le but de vérifier si la performance de notre portefeuille ESG ne résulte pas d'autres facteurs liés aux marchés nous utilisons le modèle de Fama-french a 5 facteurs.

OLS Regression Results						
Dep. Variable:	Excess_ret	R-squared:	0.900			
Model:	OLS	Adj. R-squared:	0.837			
Method:	Least Squares	F-statistic:	14.36			
Date:	Mon, 21 Jun 2021	Prob (F-statistic):	0.000804			
Time:	07:20:01	Log-Likelihood:	-45.226			
No. Observations:	14	AIC:	102.5			
Df Residuals:	8	BIC:	106.3			
Df Model:	5					
Covariance Type:	nonrobust					
	coef	std err	t	P> t	[0.025	0.975]
Intercept	9.5557	3.521	2.714	0.026	1.437	17.674
Mkt_RF	0.5712	0.178	3.208	0.012	0.161	0.982
SMB	0.2380	0.457	0.521	0.617	-0.816	1.292
HML	1.0920	0.289	3.773	0.005	0.425	1.759
RMW	-1.3274	0.511	-2.597	0.032	-2.506	-0.149
CMA	-1.7679	0.552	-3.201	0.013	-3.042	-0.494
Omnibus:	0.212	Durbin-Watson:		1.169		
Prob(Omnibus):	0.899	Jarque-Bera (JB):		0.294		
Skew:	0.232	Prob(JB):		0.863		
Kurtosis:	2.463	Cond. No.		31.4		

On remarque que 4 des 5 facteurs choisis sont significatifs. Le seul facteur non-significatif est la taille du marché. Les portefeuilles basés sur les ESG sont affectés par les facteurs Fama et French, négativement par la rentabilité (RMW) et le climat d'investissement (CMA) et positivement par la valeur (HML) et le Market return (Mkt_RF).

Chapitre 8

Conclusion

En s'appuyant sur les travaux de Bloomberg concernant les signals des données ESG, nous avons construit différents portefeuilles dans le but de battre nos différents Benchmark que sont l'EuroStocks 50, l'euronext100 et le S&P500. Nos résultats ont été satisfaisants (avec un ratio de Sharpe de 1.81 pour la RandomForest contre 1.63 pour l'EuroStocks 50), on présente des rendements bien supérieurs malgré une volatilité plus élevée.

Nous avons construit ces portefeuilles en reproduisant la majeure partie de la méthodologie employé dans l'article, en y ajoutant des axes améliorations. Nous avons été plus loin dans les imputations de données, qui sont au coeur de la problématique ESG. De plus nous avons ajouté la RandomForest en algorithme de Machine Learning. Cette innovation a été récompensée car c'est le modèle qui nous a donné les meilleurs résultats (Random Forest avec imputation VAE).

Le problème majeur que nous avons rencontré dans la reproduction de l'article était le manque des données. Les chercheurs du QuantLab de Bloomberg avaient un accès à toutes les données ESG disponible.

Le peu de données que nous avons pu avoir et la basse fréquence des données ESG n'étaient pas suffisants pour tester toutes méthodes que nous voulions tenter. Nous avons dû nous adapter contraintes concernant les données ainsi qu'à leur faible fréquence de parution afin de tirer la analyse possible pour ce projet.

Une autre critique par rapport à l'article de Bloomberg serait l'absence de résultats sur les performances des modèles (des métriques tels que F1-Score). En absence des métriques de performances nous avons pas pu comparé nos résultats aux leurs.